

INFORME DE ANÁLISIS

Reto 6 — Creación de un dataset enriquecido con Open Data

El Mercado de las Especies de Dataclysm

Autora: Judit Giravent
Fecha: 09/2026
Herramientas: Python 3.13 · pandas · matplotlib · seaborn · World Bank Open Data · ONS Nomis
Dataset principal: Online Retail II (UCI Machine Learning Repository) — 767.853 transacciones limpias
Open Data: World Bank (UK Economic Indicators) + ONS (Población por región)

Índice

1. Resumen ejecutivo
2. Introducción y contexto
3. Paso 1: Selección del dataset principal
4. Paso 2: Búsqueda y selección de Open Data
5. Paso 3: Preparación de datos
6. Paso 4: Integración de datasets
7. Paso 5: Análisis comparativo
8. Paso 6: Conclusiones y recomendaciones
9. Anexos

1. Resumen ejecutivo

Este proyecto enriquece un dataset comercial de ventas con **Open Data** procedente del **World Bank** y del **ONS (Office for National Statistics)**, para realizar un análisis comparativo que revele insights imposibles de obtener con los datos internos por sí solos.

Resultados principales

- **Dataset enriquecido:** 767.853 transacciones con 25 columnas (18 originales + 4 Open Data + 3 derivadas).
- **Impacto de la inflación:** las ventas reales de 2011 perdieron **£282.555** (3,71%) por el aumento de la inflación (2,49% → 3,86%).
- **Caída del Q4 2011:** la campaña navideña cayó un **16,9%** respecto a 2010, coincidiendo con el pico de inflación y desempleo.
- **Divergencia con la economía:** el PIB UK creció un **+7,2%** entre 2010 y 2011, mientras las ventas de la tienda cayeron un **-7%**.

Conclusión principal

El Open Data ha permitido **contextualizar las ventas en el entorno macroeconómico británico**, revelando que la tienda **no está aprovechando el crecimiento económico del país** y que sufre especialmente en períodos de alta inflación.

2. Introducción y contexto

2.1 Contexto narrativo

En la isla de Dataclysm, los mercaderes del Mercado de las Especias han acumulado grandes volúmenes de datos internos. Sin embargo, para comprender su posición real en el mercado, necesitan **comparar sus operaciones con información del mundo exterior**.

La **Torre del Conocimiento** simboliza el acceso a la vasta red de **Open Data** — datos públicos, gratuitos y abiertos — que permiten enriquecer el análisis con contexto económico, demográfico y social.

2.2 Objetivo del reto

Utilizar datos abiertos para enriquecer un conjunto de datos comerciales y realizar un **análisis comparativo** que revele nuevas perspectivas.

2.3 Metodología

Paso	Descripción	Herramienta
1	Selección del dataset principal	UCI Repository
2	Búsqueda de Open Data	World Bank + ONS
3	Preparación de datos	pandas
4	Integración de datasets	pandas (merge)
5	Análisis comparativo	matplotlib + seaborn
6	Conclusiones y recomendaciones	Análisis de negocio

3. Paso 1: Selección del dataset principal

3.1 Enfoque del análisis

Se decidió trabajar con **datos de ventas** porque permiten:

- Analizar tendencias temporales y estacionalidad.
- Detectar patrones de comportamiento del cliente.
- Evaluar el impacto de factores externos (economía, inflación, desempleo).

3.2 Dataset seleccionado

Nombre: Online Retail II
Fuente: UCI Machine Learning Repository
URL: <https://archive.ics.uci.edu/dataset/502/online+retail+ii>
Periodo: Diciembre 2009 – Diciembre 2011
País: Reino Unido

Característica	Valor
Instancias originales	1.067.371
Instancias tras limpieza	767.853
Variables	18 columnas
Tipo	Transacciones de comercio electrónico

3.3 Justificación

- 1. **Dataset real y grande** (casi 1M transacciones).
- 2. **Variable temporal** (`InvoiceDate`) que permite cruzar con Open Data por año.
- 3. **País identificado** (`Country`) que permite cruzar con indicadores UK.
- 4. **Volumen suficiente** para un análisis comparativo significativo.

3.4 Estructura del dataset principal

Variable	Tipo	Descripción
<code>InvoiceNo</code>	Texto	Número de factura
<code>StockCode</code>	Texto	Código de producto
<code>Description</code>	Texto	Nombre del producto
<code>Quantity</code>	Entero	Cantidad vendida
<code>InvoiceDate</code>	Fecha	Fecha y hora de la transacción
<code>UnitPrice</code>	Decimal	Precio unitario
<code>CustomerID</code>	Entero	Identificador del cliente
<code>Country</code>	Texto	País de residencia
<code>TotalPrice</code>	Decimal	Importe total ($Quantity \times UnitPrice$)
<code>Year</code>	Entero	Año de la transacción

4. Paso 2: Búsqueda y selección de Open Data

4.1 Tipos de Open Data seleccionados

Se decidió buscar **indicadores económicos del Reino Unido** porque:

- El dataset principal es de una tienda británica.
- Los indicadores macroeconómicos permiten contextualizar las ventas.
- Permiten crear variables derivadas (ventas ajustadas por inflación, ventas per cápita, etc.).

4.2 Fuentes seleccionadas

Fuente	Open Data	Años
World Bank Open Data	PIB (GDP, current US\$)	2009-2011
World Bank Open Data	Inflación (CPI, annual %)	2009-2011
World Bank Open Data	Desempleo (Unemployment, total %)	2009-2011
World Bank Open Data	Población total UK	2009-2011
ONS Nomis	Población por región UK	2009-2011

4.3 Justificación de la elección

Criterio	Cumple
Fuente confiable	World Bank y ONS son organismos oficiales
Datos gratuitos y abiertos	Licencia Open Data
Compatible estructuralmente	Variable común: <code>Year</code>
Período coincidente	2009-2011 (igual que el dataset principal)
Aporte de valor	Contexto macroeconómico y demográfico

4.4 Indicadores obtenidos

Indicador	2009	2010	2011
PIB (US\$)	2,43 B	2,50 B	2,68 B
Inflación (%)	1,96%	2,49%	3,86%
Desempleo (%)	7,68%	7,97%	8,20%
Población total	62.276.270	62.766.365	63.258.810

5. Paso 3: Preparación de datos

5.1 Limpieza del dataset principal

Paso	Filas antes	Filas después	Eliminadas
Carga inicial	995.416	—	—
Eliminar nulos en CustomerID y Description	995.416	767.853	-227.563
Eliminar duplicados	767.853	767.853	0
Eliminar Quantity/UnitPrice ≤ 0	767.853	767.853	0

Resultado: 767.853 filas limpias (77,1% del original).

5.2 Limpieza del Open Data

Para cada archivo del World Bank (PIB, inflación, desempleo, población):

1. **Filtrar solo United Kingdom** (Country Code = GBR).
2. **Seleccionar los años 2009, 2010, 2011.**
3. **Transformar de formato ancho a largo** (de columnas de años a filas).
4. **Unir todos los indicadores** en una sola tabla por año.

Para el archivo ONS de población por región:

1. **Leer el archivo Excel** (12 regiones $\times$ 3 años).
2. **Transformar de formato ancho a largo.**
3. **Guardar como CSV limpio.**

5.3 Estructura compatible

Ambos datasets se han alineado con la variable común `Year` (entero) para permitir el cruce.

6. Paso 4: Integración de datasets

6.1 Tipo de integración

Se utilizó un **Left Join** (unión a la izquierda) porque:

- Preserva **todas las filas** del dataset principal.
- Añade los indicadores económicos donde coincida el año.
- Los años del principal (2009-2011) coinciden perfectamente con los del Open Data.

6.2 Resultado de la integración

Métrica	Valor
Filas antes	767.853
Filas después	767.853
Columnas antes	18
Columnas después	25
Nulos en columnas Open Data	0 (100% coincidencia)

6.3 Nuevas variables creadas

Variable	Fórmula	Uso
TotalPrice_Ajustado_Inflacion	TotalPrice / (1 + Inflation_pct/100)	Valor real de las ventas
ventas_por_PIB	TotalPrice / GDP_USD × 10 ⁹	Contribución relativa al PIB
ventas_per_Capita	TotalPrice / Population_Total	Gasto por habitante

7. Paso 5: Análisis comparativo


7.1 Agregación anual

Año	Ventas Totales	Ventas Ajustadas	Pérdida Inflación	Pedidos	Clientes
2009	£641.499	£629.157	1,92%	1.500	952
2010	£8.186.504	£7.987.406	2,43%	18.145	4.208
2011	£7.610.008	£7.327.453	3,71%	16.990	4.202

Nota: 2009 es un año parcial (solo diciembre).

7.2 Hallazgo 1 — Impacto de la inflación en las ventas

 Ventas nominales vs ajustadas




Análisis:

- **2011 fue el año con mayor inflación** (3,86%), y por tanto, la mayor pérdida de poder adquisitivo.
- Las ventas nominales de 2011 (£7,61M) equivalen a solo **£7,33M en precios de 2010**.
- **Pérdida real: £282.555** por el aumento de la inflación.

Implicación: el negocio **creció menos de lo que parece** en términos nominales. La inflación erosiona márgenes si no se ajustan precios.

7.3 Hallazgo 2 — Caída del Q4 2011

Comparativa trimestral 2010 vs 2011



Trimestre	2010	2011	Variación
Q1	£1.635.045	£1.444.573	-11,65%
Q2	£1.753.506	£1.655.063	-5,61%
Q3	£1.899.494	£2.101.657	+10,64%
Q4	£2.898.459	£2.408.715	-16,90%


Análisis:

- El **Q4 (campana navideña)** cayó un **16,9%** en 2011.
- Coincide con el **pico de inflación (3,86%)** y desempleo (8,20%) en UK.
- Los consumidores redujeron el gasto discrecional navideño.
- **Pérdida estimada: £489.744** en el Q4.

Implicación: el Q4 es el trimestre más importante del año. Una caída del 16,9% tiene un impacto desproporcionado en el resultado anual.

7.4 Hallazgo 3 — Divergencia con el crecimiento del PIB

Ventas vs PIB



Indicador	2010	2011	Variación
PIB UK	2,50 B US\$	2,68 B US\$	+7,20%
Ventas tienda	£8.186.504	£7.610.008	-7,04%


Análisis:

- La economía británica **creció un 7,2%** entre 2010 y 2011.
- Las ventas de la tienda **cayeron un 7,0%** en el mismo período.
- **La tienda va en dirección contraria a la economía.**

Implicación: la tienda está **perdiendo cuota de mercado** o tiene un problema de competitividad. No está aprovechando el crecimiento económico del país.

7.5 Ratios económicos anuales

 Ratios económicos



Ratio	2010	2011	Variación
-------	------	------	-----------


Ventas per cápita	£0,1304	£0,1203	-7,7%
Ratio	2010	2011	Variación
Ventas por billón PIB	£3,28M	£2,84M	-13,4%
Cientes por mil hab.	0,067	0,066	-1,4%

Análisis:

- Todos los ratios caen en 2011, confirmando el **deterioro relativo** del negocio.
- La tienda factura menos por cada libra de PIB generada.

7.6 Estacionalidad y contexto económico

Estacionalidad y contexto



Análisis:

- La **estacionalidad navideña** (pico en Q4) se mantiene en ambos años.
- Pero el **pico de 2011 es más bajo** que el de 2010 (16,9% menos).
- La **inflación y el desempleo crecieron** en paralelo a la caída del Q4.

Implicación: el contexto económico adverso (inflación + desempleo) **amplificó la caída** en el trimestre clave.

8. Paso 6: Conclusiones y recomendaciones

8.1 Valor añadido del Open Data

El Open Data ha permitido:

Sin Open Data	Con Open Data
Solo veíamos ventas nominales	Vemos ventas reales (ajustadas por inflación)

No sabíamos por qué caía el Q4 2011	Sabemos que coincidió con inflación + desempleo altos
No podíamos comparar con la economía	Sabemos que la tienda va contra el PIB
No teníamos ratios de mercado	Tenemos ventas per cápita y penetración de PIB

8.2 Conclusiones clave

1. **La inflación erosiona el 3,71% de las ventas reales** en 2011.
2. **El Q4 2011 cayó un 16,9%**, coincidiendo con el pico de inflación y desempleo.
3. **La tienda no aprovecha el crecimiento económico** del país (PIB +7,2% vs ventas -7%).

8.3 Recomendaciones

Recomendaciones estratégicas

1. **Revisar la política de precios** para compensar el efecto de la inflación.

2. **Reforzar las campañas del Q4** con antelación, ajustando promociones al contexto económico.
3. **Analizar la competitividad** del negocio (¿por qué no crecemos cuando el país crece?).

Recomendaciones operativas

1. **Ajustar el stock** en función del contexto económico: menos stock en períodos de alta inflación.
2. **Segmentar las promociones** por región (los datos del ONS muestran diferencias de población).
3. **Monitorizar indicadores macro** (inflación, desempleo) para anticipar caídas.

9. Anexos

Anexo A: Estructura del proyecto

Reto6_OpenData_Retail/

- └─ datos/
 - └─ principal/ (Online Retail II limpio)
 - └─ open_data/ (Indicadores + población)
 - └─ enriquecido/ (Dataset final)
- └─ scripts/ (6 scripts Python)
- └─ salidas/
 - └─ figuras/ (12 visualizaciones)
 - └─ resultados/ (CSVs de resultados)
- └─ docs/ (4 entregables)

Anexo B: Scripts desarrollados

Script	Función
02_limpieza_principal.py	Limpieza del dataset principal
03_limpieza_open_data.py	Limpieza del Open Data
04_integracion.py	Integración de ambos datasets
05c_analisis_comparativo_final.py	Análisis comparativo

Anexo C: Fuentes de Open Data

Fuente	URL
World Bank Open Data	https://data.worldbank.org
ONS Nomis	https://www.nomisweb.co.uk

Anexo D: Glosario

Término	Definición
Open Data	Datos públicos, gratuitos y abiertos
Left Join	Unión que preserva todas las filas del dataset principal
Inflación	Aumento generalizado de precios
PIB	Producto Interior Bruto
CPI	Consumer Price Index (índice de precios al consumo)

FIN DEL INFORME

Documento generado por Judit Giravent — 09/2026